 # RNN

1. 经典 RNN

- 在实际应用中，会遇到很多序列形的数据，例如
  a) 自然语言处理问题: x_1可以看做是第一个单词，x_2可以看做是第二个单词，依次类推。
  b) 语音处理: 此时，$x_1, x_2, x_3, \ldots$是每帧的声音信号。
  c) 时间序列问题: 例如每天的股票价格等。
- 序列形的数据就不太好用原始的神经网络处理了。为了建模序列问题，RNN 引入了隐状态h（hidden state）的概念，h 可以对序列形的数据提取特征，接着再转换为输出。（可以将h视为包含了 time-step 的信息）

i. 先从h_1的计算开始看:

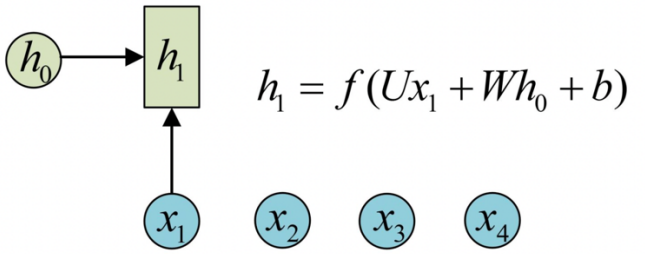

ii. h_2的计算和h_1类似。要注意的是，在计算时，每一步使用的参数U, W, b都是一样的，也就是说每个步骤的参数都是共享的，这是 **RNN 的重要特点**。

iii. 以下计算过程可以无限地持续下去。

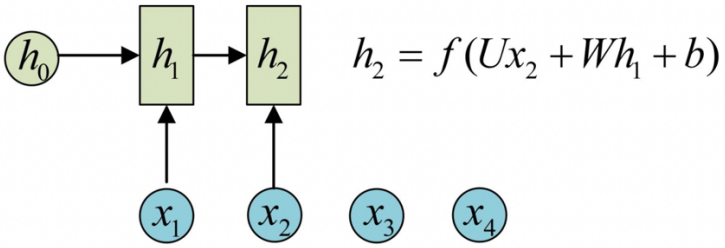

iv. 得到输出值的方式就是直接通过h进行计算

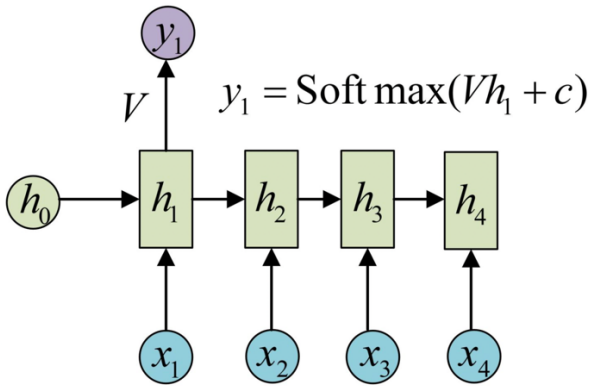

v. 完整结构

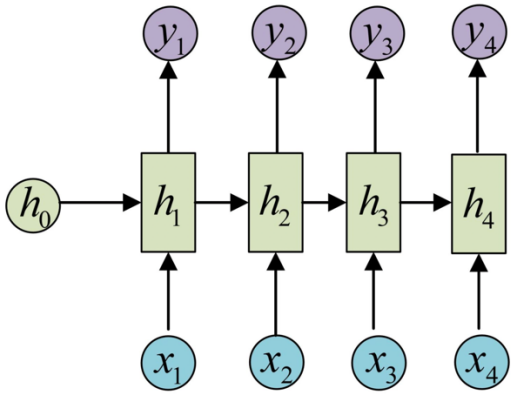

- **输入和输出序列必须要是等长的，即 N - N。**

  由于这个限制的存在，经典 RNN 的适用范围比较小，但也有一些问题适合用经典的 RNN 结构建模，如：

  a) 计算视频中每一帧的分类标签。因为要对每一帧进行计算，因此输入和输出序列等长。

  b) 输入为字符，输出为下一个字符的概率，即著名的 Char RNN。

2. RNN 变种(其他类型)

2.1 N - 1

- 要处理的问题输入是一个序列，输出是一个单独的值而不是序列
  -> 只在最后一个h上进行输出变换就可以了

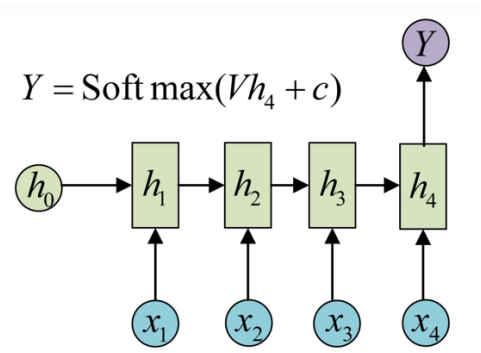

- 这种结构通常用来处理序列分类问题。

  a) 输入一段文字判别它所属的类别。

  b) 输入一个句子判断其情感倾向。

  c) 输入一段视频并判断它的类别。

  ……

2.2 1 - N

- 输入不是序列而输出为序列的情况 -> 只在序列开始进行输入计算

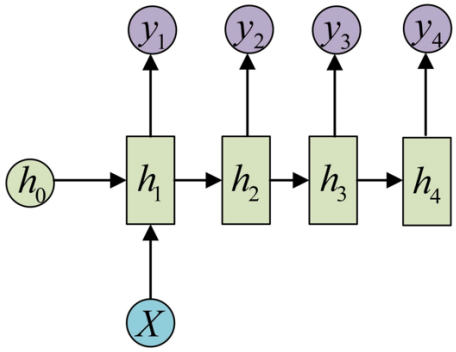

- 还有一种结构是把输入信息 X 作为每个阶段的输入

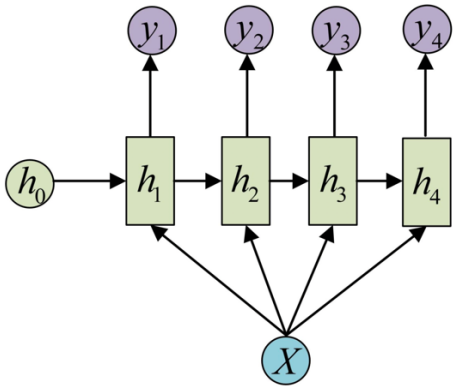

- 这种 1 VS N 的结构可以处理的问题有
  a) 从图像生成文字(image caption)，此时输入的 X 就是图像的特征，而输出的 y 序列就是一段句子。
  b) 从类别生成语音或音乐等。

2.3 N - M

- **RNN 最重要的一个变种：N - M。**

  这种结构又叫 Encoder-Decoder 模型，也可以称之为 Seq2Seq 模型。

- 原始的 RNN (N-N)要求序列等长，然而我们遇到的大部分问题序列都是不等长的，如机器翻译中，源语言和目标语言的句子往往并没有相同的长度。

  i. 为此，Encoder-Decoder 结构先将输入数据编码成一个上下文向量c
  得到c有多种方式，最简单的方法就是把 Encoder 的最后一个隐状态赋值给c，还可以对最后的隐状态做一个变换得到c，也可以对所有的隐状态做变换。

$$（1）\ c = h_4$$
$$（2）\ c = q(h_4)$$
$$（3）\ c = q(h_1, h_2, h_3, h_4)$$

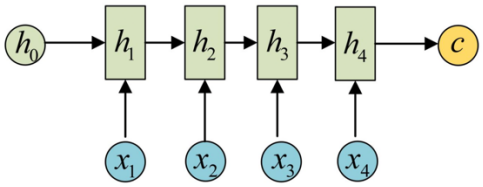

ii. 拿到c之后，就用另一个 RNN 网络对其进行解码，这部分 RNN 网络被称为 Decoder。具体做法就是将c当做之前的初始状态h_0输入到 Decoder 中。

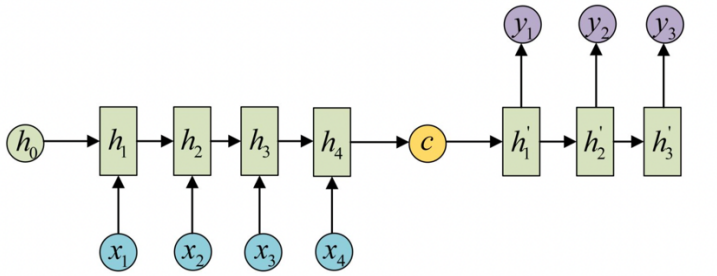

还有一种做法是将c当做每一步的输入。

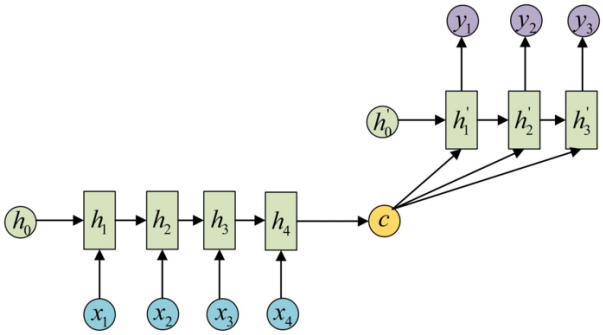

- 由于这种 Encoder-Decoder 结构不限制输入和输出的序列长度，因此应用的范围非常广泛。
  a) 机器翻译: Encoder-Decoder 的最经典应用，事实上这一结构就是在机器翻译领域最先提出的。
  b) 文本摘要：输入是一段文本序列，输出是这段文本序列的摘要序列。
  c) 阅读理解：将输入的文章和问题分别编码，再对其进行解码得到问题的答案。
  d) 语音识别：输入是语音信号序列，输出是文字序列。
  ……